

TP 2 : Détection d'un changement ponctuel dans une suite binaire

Modèles probabilistes pour l'apprentissage - MPA

Hiba HANINI, Marwane HAJJY, Hiba FAHLI

25/09/2025

Q1. Soit $c = 1$. Donner l'expression de la loi générative $p(y \mid c = 1, \theta_1, \theta_2)$

Comme les y_i sont i.i.d :

$$p(y \mid c = 1, \theta_1, \theta_2) = \prod_{i=1}^n \theta_2^{y_i} (1 - \theta_2)^{1-y_i}$$

Q2. Même question pour $c > 1$.

$$p(y \mid c, \theta_1, \theta_2) = \prod_{i=1}^{c-1} \theta_1^{y_i} (1 - \theta_1)^{1-y_i} \prod_{i=c}^n \theta_2^{y_i} (1 - \theta_2)^{1-y_i}$$

Q3. On suppose que θ_1 et θ_2 sont connues. Dédurre des questions précédentes que

$$\forall c = 2, \dots, n, \quad \frac{p(c \mid y)}{p(c = 1 \mid y)} = \prod_{j=1}^{c-1} \frac{\theta_1^{y_j} (1 - \theta_1)^{1-y_j}}{\theta_2^{y_j} (1 - \theta_2)^{1-y_j}}.$$

Vérifier que l'on peut calculer le rapport $p(c \mid y)/p(c = 1 \mid y)$ pour tout c en effectuant de l'ordre de $n(n-1)/2$ multiplications.

On a d'après la formule de Bayes, θ_1 et θ_2 connues:

$$p(c \mid y) = p(y \mid c) \cdot \frac{p(c)}{p(y)}$$

Et de même :

$$p(c = 1 \mid y) = p(y \mid c = 1) \cdot \frac{p(c = 1)}{p(y)}$$

Comme $p(c = 1) = p(c) = \frac{1}{n}$

On obtient :

$$\begin{aligned}
\forall c = 2, \dots, n, \quad \frac{p(c \mid y)}{p(c = 1 \mid y)} &= \frac{p(y \mid c)}{p(y \mid c = 1)} \\
&= \frac{\prod_{i=1}^{c-1} \theta_1^{y_i} (1 - \theta_1)^{1-y_i} \prod_{i=c}^n \theta_2^{y_i} (1 - \theta_2)^{1-y_i}}{\prod_{i=1}^n \theta_2^{y_i} (1 - \theta_2)^{1-y_i}} \\
&= \prod_{j=1}^{c-1} \frac{\theta_1^{y_j} (1 - \theta_1)^{1-y_j}}{\theta_2^{y_j} (1 - \theta_2)^{1-y_j}}
\end{aligned}$$

Ainsi :

$$\boxed{\forall c = 2, \dots, n, \quad \frac{p(c \mid y)}{p(c = 1 \mid y)} = \prod_{j=1}^{c-1} \frac{\theta_1^{y_j} (1 - \theta_1)^{1-y_j}}{\theta_2^{y_j} (1 - \theta_2)^{1-y_j}}.}$$

Si on calcule chaque rapport $\frac{p(c \mid y)}{p(c = 1 \mid y)}$ indépendamment pour chaque c , alors pour un c donné, il faut effectuer $(c - 1)$ multiplications.

Le nombre total de multiplications pour tous les $c = 2, \dots, n$ est donc :

$$\boxed{\sum_{c=2}^n (c - 1) = 1 + 2 + \dots + (n - 1) = \frac{n(n - 1)}{2}.}$$

D'où la vérification, on peut bien calculer tous les rapports en $\mathcal{O}\left(\frac{n(n-1)}{2}\right)$ multiplications.

Q4. Supposant θ_1 et θ_2 connues, proposer un algorithme permettant de calculer $p(c \mid y)$ pour tout $c = 1, \dots, n$ avec une complexité en $O(n)$.

Soit :

$$r_j = \frac{\theta_1^{y_j} (1 - \theta_1)^{1-y_j}}{\theta_2^{y_j} (1 - \theta_2)^{1-y_j}}.$$

Et :

$$R_c = \frac{p(c \mid y)}{p(c = 1 \mid y)} = \prod_{j=1}^{c-1} \frac{\theta_1^{y_j} (1 - \theta_1)^{1-y_j}}{\theta_2^{y_j} (1 - \theta_2)^{1-y_j}}$$

On peut alors écrire une récurrence linéaire :

$$\boxed{R_1 = 1, \quad R_c = R_{c-1} \times r_{c-1} \quad \text{pour } c = 2, \dots, n.}$$

On a par normalisation :

$$\begin{aligned}
\sum_{k=1}^n R_k &= \sum_{k=1}^n \frac{p(c = k \mid y)}{p(c = 1 \mid y)} \\
&= \frac{1}{p(c = 1 \mid y)}
\end{aligned}$$

Ainsi :

$$p(c \mid y) = p(c = 1 \mid y) \cdot R_c$$

Donc :

$$p(c | y) = \frac{R_c}{\sum_{k=1}^n R_k}$$

Algorithme en R

```
calculer_p_c <- function(y, theta1, theta2) {
  n <- length(y)
  R <- numeric(n)
  R[1] <- 1

  for (j in 1:(n - 1)) {
    r_j <- (theta1^y[j] * (1 - theta1)^(1 - y[j])) /
      (theta2^y[j] * (1 - theta2)^(1 - y[j]))
    R[j + 1] <- R[j] * r_j
  }

  somme <- sum(R)
  p <- R / somme
  return(p)
}

calculer_p_c_sans_recurrence <- function(y, theta1, theta2) {
  n <- length(y)
  R <- numeric(n)
  for (c in 1:n) {
    if (c == 1) {
      R[c] <- 1
    }
    else {
      prod_c <- 1
      for (j in 1:(c - 1)) {
        r_j <- (theta1^y[j] * (1 - theta1)^(1 - y[j])) /
          (theta2^y[j] * (1 - theta2)^(1 - y[j]))
        prod_c <- prod_c * r_j
      }
      R[c] <- prod_c
    }
  }
  p <- R / sum(R)
  return(p)
}

# Exemple :
y <- c(1, 0, 1, 1, 0)
theta1 <- 0.8
theta2 <- 0.4
p <- calculer_p_c(y, theta1, theta2)
p_sans_recurrence <- calculer_p_c_sans_recurrence(y, theta1, theta2)
print(p)
```

```
## [1] 0.13043478 0.26086957 0.08695652 0.17391304 0.34782609
```

```
print(p_sans_recurrence)
```

```
## [1] 0.13043478 0.26086957 0.08695652 0.17391304 0.34782609
```

Q5. On suppose désormais que θ_1 et θ_2 sont inconnues. À partir de valeurs initiales arbitraires, proposer un algorithme itératif, de type échantillonnage de Gibbs, permettant de calculer $p(c | y)$ pour tout $c = 1, \dots, n$ en combinant : - la simulation de la loi $p(c | y, \theta_1, \theta_2)$, - et la simulation de valeurs des paramètres θ_1 et θ_2 .

Tout comme le TP1, on utilise l'algorithme de Gibbs :

1. On initialise $\theta^{(0)} = (\theta_1^{(0)}, \theta_2^{(0)})$ et $c^{(0)}$ par des valeurs arbitraires (entre 0 et 1)
2. Pour tout $t \geq 1$, on considère l'itération du cycle suivant :
 - 2.1. Simuler $c^{(t)}$ selon $p(c | y, \theta_1^{(t-1)}, \theta_2^{(t-1)})$ (par la récurrence linéaire)
 - 2.2. Simuler θ_1 et θ_2 respectivement selon $p(\theta_1 | y, c^{(t)})$ et $p(\theta_2 | y, c^{(t)})$

Pour θ_1 , on a :

$$p(\theta_1 | y, c^{(t)}) \propto p(y | \theta_1, c^{(t)}) \cdot p(\theta_1)$$

Prenons la loi a priori non informative $\text{Unif}(0,1) = \text{Beta}(1,1)$: $\theta_1 \sim \text{Beta}(1,1)$

On a donc :

$$\begin{aligned} p(\theta_1 | y, c^{(t)}) &\propto p(y | \theta_1, c^{(t)}) \cdot p(\theta_1) \\ &\propto \prod_{i=1}^{c^{(t)}-1} \theta_1^{y_i} (1 - \theta_1)^{1-y_i} \\ &\propto \theta_1^{\sum_{i=1}^{c^{(t)}-1} y_i} (1 - \theta_1)^{c^{(t)}-1 - \sum_{i=1}^{c^{(t)}-1} y_i} \end{aligned}$$

Ainsi :

$$\theta_1 | y, c^{(t)} \sim \text{Beta}(s_1 + 1, m_1 - s_1 + 1)$$

De même pour θ_2 Posons : $\sum_{c^{(t)}} y_i = s_2$, $n - (c^{(t)} - 1) = m_2$, avec la loi à priori $\theta_2 \sim \mathcal{B} | \sqcup (1,1)$

$$\theta_2 | y, c^{(t)} \sim \text{Beta}(s_2 + 1, m_2 - s_2 + 1)$$

Algorithme de Gibbs

```
algorithme_gibbs <- function(
  y, n_iteration, n_elimine, c_initial, theta1_initial, theta2_initial) {
  n <- length(y)
  # 1. Initialisation de c, theta1, theta2
  c_val <- c_initial
  theta1 <- theta1_initial
  theta2 <- theta2_initial

  c_samples <- numeric(n_iteration) # les valeurs de c^{t}
  theta1_samples <- numeric(n_iteration)
  theta2_samples <- numeric(n_iteration)

  for (t in 1:n_iteration) {

    # 2.1 Tirage de c | y, theta1, theta2
    R <- numeric(n)
    R[1] <- 1
```

```

for (j in 1:(n-1)) {
  r_j <- (theta1^y[j] * (1 - theta1)^(1 - y[j])) /
    (theta2^y[j] * (1 - theta2)^(1 - y[j]))
  R[j + 1] <- R[j] * r_j
}
somme <- sum(R)
proba_c <- R / somme
c_val <- sample(1:n, 1, prob = proba_c)

# 2.2 Tirage de theta1 et theta2 / y, c
s1 <- if (c_val > 1) sum(y[1:(c_val - 1)]) else 0
m1 <- c_val - 1
s2 <- sum(y[c_val:n])
m2 <- n - m1

theta1 <- rbeta(1, 1 + s1, 1 + m1 - s1)
theta2 <- rbeta(1, 1 + s2, 1 + m2 - s2)

# Sauvegarde des tirages
c_samples[t] <- c_val
theta1_samples[t] <- theta1
theta2_samples[t] <- theta2
}

# Suppression des itérations de burn-in
c_samples <- c_samples[(n_elimine + 1):n_iteration]
theta1_samples <- theta1_samples[(n_elimine + 1):n_iteration]
theta2_samples <- theta2_samples[(n_elimine + 1):n_iteration]

# Estimation de p(c | y)
p_c <- table(factor(c_samples, levels = 1:n)) / length(c_samples)

list(p_c = p_c,
     c_samples = c_samples,
     theta1_samples = theta1_samples,
     theta2_samples = theta2_samples)
}

```

Q6. Tester la convergence de votre algorithme en examinant la sensibilité aux conditions initiales choisies arbitrairement.

```

y <- c(0, 0, 0, 0, 1, 1, 1, 1, 1, 1)

res1 <- algorithm_gibbs(y, n_iteration = 10000, n_elimine = 1000,
                       c_initial = 1, theta1_initial = 0.1, theta2_initial = 0.9)

res2 <- algorithm_gibbs(y, n_iteration = 10000, n_elimine = 1000,
                       c_initial = 8, theta1_initial = 0.9, theta2_initial = 0.1)


par(mfrow = c(2, 2))

plot(res1$theta1_samples, type = "l", col = "blue", main = expression(theta[1]))
lines(res2$theta1_samples, col = "red")

```

```
plot(res1$theta2_samples, type = "l", col = "blue", main = expression(theta[2]))
lines(res2$theta2_samples, col = "red")
```

```
barplot(res1$p_c, main = "p(c|y)
      avec c = 1, theta1 = 0.1, theta2 = 0.9", col = "blue")
barplot(res2$p_c, main = "p(c|y)
      avec c = 8, theta1 = 0.9, theta2 = 0.1", col = "red")
```




Q7. Analyser les jeux de données envoyés en pièce jointe par l'enseignant. Décrire l'incertitude sur le(s) point(s) de changement pour ces jeux de données (localisation des points des changements et intervalles contenant chacun des points avec une probabilité supérieure à 50%).

Séquence 1 :

```
seq1 <- scan("TP2_sequence_1.txt")
res1 <- algorithm_gibbs(seq1, n_iteration = 10000, n_elimine = 1000,
      c_initial = 1, theta1_initial = 0.2, theta2_initial = 0.8)

barplot(res1$p_c, main = "Distribution de p(c|y) - Seq 1", col = "red",
      xlab = "position c", ylab = "p(c|y)" )
```

Distribution de $p(c|y)$ – Seq 1



On remarque que la courbe est unimodale, on a donc un point de changement :

```
point_estime <- which.max(as.numeric(res1$p_c))
print(point_estime)
```

```
## [1] 56
```

Pour le premier point de changement :

```
IC <- quantile(res1$c_samples, probs = c(0.125, 0.875))
freq_avant <- mean(seq1[1:(point_estime - 1)])
freq_apres <- mean(seq1[point_estime:length(seq1)])

print("Résultats pour seq1, point c = 56 :")
```

```
## [1] "Résultats pour seq1, point c = 56 :"
```

```
print(IC)
```

```
## 12.5% 87.5%
```

```
## 43 57
```

```
print(freq_avant)
```

```
## [1] 0.2545455
```

```
print(freq_apres)
```

```
## [1] 0.6533333
```

On vérifie quand-même à droite et à gauche du point de changement si aucun point de changement n'existe :


```
res1Gauche <- algorithm_gibbs(seq1[1:(point_estime-1)], n_iteration = 10000,
                             n_elimine = 1000,
                             c_initial = 1, theta1_initial = 0.2,
```

```

theta2_initial = 0.8)

barplot(res1Gauche$p_c, main = "Distribution de p(c|y) - Partie Gauche
de la chaine avant le point estimé",
col = "red", xlab = "position c", ylab = "p(c|y)" )

```



On remarque que la courbe n'est pas unimodale. On peut dire qu'il n'existe pas de point de changement avant le premier estimé en $c = 56$.

De même pour la partie droite :


```

res1Droite <- algorithm_gibbs(seq1[(point_estime+1):length(seq1)],
                             n_iteration = 10000, n_elimine = 1000,
                             c_initial = 1, theta1_initial = 0.2, theta2_initial = 0.8)

barplot(res1Droite$p_c, main = "Distribution de p(c|y) -
Partie Droite de la chaine avant le point estimé",
col = "red", xlab = "position c", ylab = "p(c|y)" )

```


Distribution de $p(c|y)$ – Partie Droite de la chaîne avant le point estimé



On remarque que pour :

```
point_estime_droite <- which.max(as.numeric(res1Droite$p_c))
position_droite <- point_estime + point_estime_droite
print(position_droite)
```

```
## [1] 110
```

On a un mode en $c_{droite} = 54$, donc un autre point de changement. Cela correspond à la position 56 (point ou on a découpé) + $c_{droite} = 110$

```
IC_2 <- quantile(res1Droite$c_samples, probs = c(0.125, 0.875)) + point_estime
freq_avant_2 <- mean(seq1[(point_estime + 1):(position_droite - 1)])
freq_apres_2 <- mean(seq1[(position_droite + 1):length(seq1)])

print("Résultats pour seq1, point c = 110 :")
```

```
## [1] "Résultats pour seq1, point c = 110 :"
```

```
print(IC_2)
```

```
## 12.5% 87.5%
```

```
##    67    120
```

```
print(freq_avant_2)
```

```
## [1] 0.7358491
```

```
print(freq_apres_2)
```

```
## [1] 0.45
```

Conclusion : les deux positions 56 et 110 sont deux points de changement

Récapitulatif


```
plot(seq1, type = "h", main = "Seq1 avec les deux points de changement estimés",
     xlab = "Position", ylab = "Valeur", col = "darkgray")

# Premier point de changement
abline(v = point_estime, col = "red", lwd = 2)

# Deuxième point de changement
abline(v = position_droite, col = "red", lwd = 2)

legend("topleft",
      legend = "Points estimés",
      col = "red", lwd = 2, lty = 1, bty = "n"
    )
```

Seq1 avec les deux points de changement estimés



```
# Recap des résultats
```

```
resultats <- data.frame(
  Point_de_changement = c(point_estime, position_droite),
  IC_bas = c(IC[1], IC_2[1]),
  IC_haut = c(IC[2], IC_2[2]),
  Frequence_avant = c(freq_avant, freq_avant_2),
  Frequence_apres = c(freq_apres, freq_apres_2)
)


print(resultats)
```

##	Point_de_changement	IC_bas	IC_haut	Frequence_avant	Frequence_apres
## 1	56	43	57	0.2545455	0.6533333
## 2	110	67	120	0.7358491	0.4500000

Séquence 2 :

```
seq2 <- scan("TP2_sequence_2.txt")
res2 <- algorithme_gibbs(seq2, n_iteration = 10000, n_elimine = 1000,
                        c_initial = 1, theta1_initial = 0.2, theta2_initial = 0.8)

barplot(res2$p_c, main = "Distribution de p(c|y) - Seq 2", col = "red",
        xlab = "position c", ylab = "p(c|y)" )
```



De même que la seq1, on remarque que la courbe est unimodale, on a donc un point de changement :

```
point_estime_seq2 <- which.max(as.numeric(res2$p_c))
print(point_estime_seq2)
```

```
## [1] 315
```

Pour le premier point de changement :

```
IC_seq2 <- quantile(res2$c_samples, probs = c(0.125, 0.875))
freq_avant_seq2 <- mean(seq2[1:(point_estime_seq2 - 1)])
freq_apres_seq2 <- mean(seq2[point_estime_seq2:length(seq2)])

print("Résultats pour seq1, point c = 56 :")
```

```
## [1] "Résultats pour seq1, point c = 56 :"
```

```
print(IC_seq2)
```

```
## 12.5% 87.5%
```

```
## 311 318
```

```
print(freq_avant_seq2)
```

```
## [1] 0.3312102
```


```
print(freq_apres_seq2)
```

```
## [1] 0.8705882
```

On vérifie quand-même à droite et à gauche du point de changement :

```
res2Gauche <- algorithm_gibbs(seq2[1:(point_estime_seq2-1)],  
                             n_iteration = 10000, n_elimine = 1000,  
                             c_initial = 1, theta1_initial = 0.2, theta2_initial = 0.8)
```

```
barplot(res2Gauche$p_c, main = "Distribution de p(c|y) -  
Partie Gauche de la chaine seq2 avant le point estimé",  
        col = "red", xlab = "position c", ylab = "p(c|y)" )
```



On remarque que la courbe est encore unimodale. Le point :

```
point_estime_gauche_seq2 <- which.max(as.numeric(res2Gauche$p_c))  
print(point_estime_gauche_seq2)
```

```
## [1] 49
```

est un point de changement. Avec

```
IC_2_seq2 <- quantile(res2Gauche$c_samples, probs = c(0.125, 0.875))  
freq_avant_2_seq2 <- mean(seq2[1:(point_estime_gauche_seq2 - 1)])  
freq_apres_2_seq2 <- mean(seq2[(point_estime_gauche_seq2 + 1):point_estime_seq2])  
  
print("Résultats pour seq2, point c = 49 :")
```

```
## [1] "Résultats pour seq2, point c = 49 :"
```

```
print(IC_2_seq2)
```

```
## 12.5% 87.5%
## 34 50
```

```
print(freq_avant_2_seq2)
```

```
## [1] 0.1041667
```


```
print(freq_apres_2_seq2)
```

```
## [1] 0.3721805
```

Pour la partie droite :

```
res2Droite <- algorithm_gibbs(seq2[(point_estime_seq2+1):length(seq2)],
                             n_iteration = 10000, n_elimine = 1000,
                             c_initial = 1, theta1_initial = 0.2, theta2_initial = 0.8)
```

```
barplot(res2Droite$p_c, main = "Distribution de p(c|y) -
Partie Droite de la chaine seq2 après le point estimé",
        col = "red", xlab = "position c", ylab = "p(c|y)" )
```



Pas de

mode, donc pas de point de changement.

On illustre les résultats pour la seq2 :

```
plot(seq2, type = "h", main = "Seq2 avec les deux points de changement estimés",
     xlab = "Position", ylab = "Valeur", col = "darkgray")
```

```
# Premier point de changement
```

```
abline(v = point_estime_seq2, col = "red", lwd = 2)
```

```
# Deuxième point de changement
```


```
abline(v = point_estime_gauche_seq2, col = "red", lwd = 2)
```

```

legend("topleft",
      legend = "Points estimés",
      col = "red", lwd = 2, lty = 1, bty = "n"
    )

```

Seq2 avec les deux points de changement estimés



```

resultats_seq2 <- data.frame(
  Point_de_changement = c(point_estime_gauche_seq2, point_estime_seq2),
  IC_bas = c(IC_2_seq2[1], IC_seq2[1]),
  IC_haut = c(IC_2_seq2[2], IC_seq2[2]),
  Frequence_avant = c(freq_avant_2_seq2, freq_avant_seq2),
  Frequence_apres = c(freq_apres_2_seq2, freq_apres_seq2)
)

print(resultats_seq2)

```

```

##   Point_de_changement IC_bas IC_haut Frequence_avant Frequence_apres
## 1                49    34    50      0.1041667      0.3721805
## 2               315   311   318      0.3312102      0.8705882

```

Pour calculer les corrélations entre les paramètres pour seq1 et seq2 :

```

# --- Corrélation entre les paramètres pour la Séquence 1 ---
par(mfrow = c(1, 3))
plot(res1$theta1_samples, res1$theta2_samples, col = "red",
     main = expression(paste("Corrélation ", theta[1], " - ", theta[2], " (Seq1)")),
     xlab = expression(theta[1]), ylab = expression(theta[2]),
     pch = 16, cex = 0.6)

plot(res1$theta1_samples, res1$c_samples, col = "blue",
     main = expression(paste("Corrélation ", theta[1], " - c (Seq1)")),


```

```

xlab = expression(theta[1]), ylab = "c",
pch = 16, cex = 0.6)

plot(res1$theta2_samples, res1$c_samples, col = "darkgreen",
main = expression(paste("Corrélation ", theta[2], " - c (Seq1)")),
xlab = expression(theta[2]), ylab = "c",
pch = 16, cex = 0.6)

```




```

# --- Corrélation entre les paramètres pour la Séquence 2 ---
par(mfrow = c(1, 3))
plot(res2$theta1_samples, res2$theta2_samples, col = "red",
main = expression(paste("Corrélation ", theta[1], " - ", theta[2], " (Seq2)")),
xlab = expression(theta[1]), ylab = expression(theta[2]),
pch = 16, cex = 0.6)

plot(res2$theta1_samples, res2$c_samples, col = "blue",
main = expression(paste("Corrélation ", theta[1], " - c (Seq2)")),
xlab = expression(theta[1]), ylab = "c",
pch = 16, cex = 0.6)

plot(res2$theta2_samples, res2$c_samples, col = "darkgreen",
main = expression(paste("Corrélation ", theta[2], " - c (Seq2)")),
xlab = expression(theta[2]), ylab = "c",
pch = 16, cex = 0.6)

```



Corrélation $\theta_1 - \theta_2$: Le nuage de points (en rouge) montre une corrélation faible. Cela est cohérent avec le modèle : θ_1 représente la probabilité avant le point de changement, θ_2 celle après.

Si la proportion avant augmente, celle après doit logiquement baisser. Le nuage montre qu'il n'y a pas de dépendance forte : bonne exploration conjointe de l'espace de paramètres. Bon signe pour la convergence.